

VIQA Nexus

Hệ thống hỏi đáp tiếng Việt có dẫn nguồn, Gia sư Socratic và vòng lặp phản hồi



Giảng viên hướng dẫn: Trần Hồng Việt — Trường Đại học Công nghệ, ĐHQGHN

Nguyễn Tùng Dương
24022306 • Document Retriever

Tổng Đức Hồng Anh
2402258 • Reader & Extractor

Lê Toàn
24022466 • Dataset & Preprocessing

Lê Ngọc Quý
23021677 • Integration & UI/3D

Bài toán & Động lực nghiên cứu

Problem Statement

Thách thức trong Question Answering (QA)

- ❗ **Tìm kiếm truyền thống:** Chỉ trả về danh sách tài liệu, bắt người dùng tự đọc tìm câu trả lời.
- 🧠 **Hạn chế tính toán:** Reader/LLM không thể đọc trực tiếp toàn bộ kho tài liệu lớn (5,317 tài liệu) do chi phí GPU & độ trễ quá cao.
- 🐱 **Rủi ro Ảo giác (Hallucination):** Mô hình ngôn ngữ tự do thường tự sáng tạo câu trả lời khi thiếu tri thức.

Giải pháp Kiến trúc Retriever-Reader

- 🔍 **Retriever:** Thu hẹp không gian tìm kiếm từ hàng ngàn tài liệu xuống Top-K passage liên quan nhất.
- 📖 **Reader:** Trích xuất chính xác span câu trả lời từ các passage được chọn.
- 🔗 **Closed-Domain Grounding:** Câu trả lời bắt buộc phải có minh chứng (Evidence) và vị trí Offset tương minh.



Nguyên tắc lỗi: Hệ thống sẵn sàng trả về trạng thái Từ chối (No-Answer / Abstention) khi bằng chứng trong kho tài liệu không đủ hoặc câu hỏi sai tiền đề.

Mục tiêu Dự án VIQA Nexus

Project Objectives

Modular Pipeline

Xây dựng hệ thống QA tiếng Việt cho phép linh hoạt thay đổi Retriever và Reader/LLM qua cấu hình JSON.

Source Traceability

Bảo toàn truy vết chính xác từ Answer → Document Title → Passage → Character Offset trong văn bản gốc.

Semantic Validation

Kiểm soát câu trả lời bằng các Semantic Gates có thể kiểm toán (Subject, Relation, Completeness, Evidence).

Socratic Tutor

Gợi mở học tập bằng câu hỏi nối tiếp có nguồn (grounded one-hop), hoàn toàn không dùng LLM sinh ngoài.

Feedback Loop

Thu thập phản hồi theo quy trình Human-in-the-Loop, tuyệt đối không tự học runtime để tránh ô nhiễm dữ liệu.

Modern UI / 3D Avatar

Giao diện Chat responsive với avatar 3D Mari, giọng nói đa phương thức và trang quản trị Evaluation/Blind Spots.

Tổng quan Dự án qua Con số

Projectata Glance

28,454

Câu hỏi Tập Train

3,814

Câu hỏi Tập Validation

7,301

Câu hỏi Tập Test

5,317

Tài liệu Kho (SQLite)

6,544

Đoạn văn (Passages)

4

Phương pháp Retriever



Lưu ý quan trọng từ Báo cáo: Tập Test (7,301 câu) không có Gold Answer công bố cho Reader, nhưng mỗi câu đều gắn Context. Kết quả Test dùng để Benchmark Retriever cấp độ Document, không phải chất lượng End-to-End.

Tập dữ liệu UIT-ViQuAD 2.0 & Corpus

Table 3.1

Hệ thống sử dụng tập dữ liệu chuẩn mực **UIT-ViQuAD 2.0** đã qua xử lý, được lưu trữ dưới dạng định dạng Parquet và CSDL SQLite.

Tập Dữ liệu (Split)	Tổng số câu hỏi	Có đáp án (Answerable)	Không đáp án / Không công bố Gold
Train	28,454	19,238	9,216
Validation	3,814	2,653	1,161
Test	7,301	0	7,301 (dùng cho Benchmark Retriever)

Đặc điểm Corpus

Lưu trữ tại docs.db (SQLite) gồm 5,317 văn bản gốc được chia nhỏ tự động thành 6,544 passages khi khởi động API.

Quy tắc Phân đoạn

Mỗi passage có độ dài tối đa 220 tokens, chồng lấn (overlap) 2 câu để tránh mất thông tin ở biên chunk.

Quy trình Xử lý Dữ liệu & Sentence-Aware Chunking

Data Pipeline



Chi tiết Thuật toán Chunking

- ✓ Module backend/chunking.py tách paragraph, tách câu bằng PyVi.
- ✓ Câu đơn quá dài được cắt theo dấu chấm phẩy, hai chấm, phẩy hoặc cửa sổ từ.
- ✓ Mỗi passage lưu vết document_id, passage_id, sentence_start, sentence_end.

Chuẩn hóa Tiêu đề Nguồn (Source Title)

Hàm derive_source_title ưu tiên:

- 1 Document title / Heading từ metadata
- 2 Entity chính ở đầu passage
- 3 First sentence truncated (không xóa ngoặc chứa năm sinh/mất)

Kiểm tra Tính Toàn vẹn Span (Span Integrity)

Table 3.2

Báo cáo thực hiện kiểm tra ánh xạ từ answer_start và answer_text sang offset từ vựng thực tế để phát hiện lỗi ranh giới Tokenizer.

Tập dữ liệu	Số mẫu có đáp án	Span hợp lệ	Span lỗi offset	Độ chính xác ánh xạ (%)
Train Split	19,238	18,913	325	98.31%
Validation Split	2,653	2,614	39	98.53%

Phân tích Nguyên nhân Lỗi (Error Diagnosis)

Phần lớn các lỗi còn lại (1.47% - 1.69%) được dán nhãn TOKENIZER_BOUNDARY do xung đột giữa quy tắc tách từ tiếng Việt của PyVi và WordPiece/BPE Tokenizer. Đây là điểm nghẽn hạ tầng ảnh hưởng trực tiếp tới **Answerable Exact Match (EM)**.

Kiến trúc Runtime Tổng thể


Luồng Xử lý Trực tuyến (Online Flow)

React Chat UI → HTTP API Gateway (Port 8000) → Retriever Pool
(BM25/Dense/Hybrid) → Reader Layer (XLM-R Extractive / LFM2.5 Generative) →
Semantic Gate Cascade → Final Answer + Source.

Hai Lớp Hậu xử lý Độc lập

- **Socratic Follow-ups:** Gợi mở câu hỏi 1-hop grounded.
- **Human Feedback Review Queue:** Lưu trữ tại SQLite WAL.

* Lớp hậu xử lý tách biệt giúp lỗi Socratic/Feedback không làm nghẽn API QA chính.



Bốn Phương pháp Retriever được Hỗ trợ

RetrievalLayer

Phương pháp	Nguyên lý Hoạt động	Ưu điểm Nổi bật	Hạn chế / Chi phí
TF-IDF	Vector thừa dựa trên TF & IDF (unigram + bigram, DrQA style)	Cực kỳ nhẹ, đơn giản, dễ giải thích	Không hiểu ngữ nghĩa, yếu với từ đồng nghĩa
BM25	BM25 Okapi ($k_1=1.5$, $b=0.75$) + Title match + Lead boost	Truy hồi từ khóa chính xác, độ tin cậy cao	Bỏ sót các câu hỏi paraphrase ngữ nghĩa
Dense	vietnamese-sbert + Cosine similarity (FAISS offline)	Bắt được ngữ nghĩa sâu, khớp paraphrase tốt	Tốn VRAM/RAM, nhạy cảm với dữ liệu out-of-domain
Hybrid	Hợp nhất BM25 + Dense bằng Reciprocal Rank Fusion ($K=60$)	Kết hợp cả độ chính xác từ khóa và ngữ nghĩa	Chi phí tính toán cao hơn, QPS giảm còn 44.8

Công thức RRF: $RRF(d) = \frac{1}{60 + r_{\{BM25\}}(d)} + \frac{1}{60 + r_{\{Dense\}}(d)}$. Điểm số sau đó được Min-Max Normalize trong Top-K Candidate Pool.

Kết quả Benchmark Retriever trên 7,301 Câu hỏi Test

Table 10.1

Phương pháp	MRR	Recall@1 (%)	Recall@3 (%)	Recall@5 (%)	Recall@10 (%)	QPS (Query/s)
TF-IDF	0.6512	55.82%	71.21%	76.34%	81.42%	51.3
BM25	0.6856	59.46%	74.44%	79.70%	85.07%	56.8
Dense (SBERT)	0.7321	66.54%	80.12%	85.41%	89.23%	213.5*
Hybrid (BM25+Dense)	0.7682	69.81%	83.45%	88.12%	91.56%	44.8

 **Kết luận Quality**

Hybrid vượt trội tuyệt đối: Tăng +6.49% Recall@1 và +6.49% Recall@10 so với BM25. Đạt tỷ lệ tìm thấy tài liệu chứa đáp án trong Top 10 tới 91.56%.

 **QPS & Runtime Note**

*QPS của Dense cao (213.5) do đo trên FAISS index đã precompute offline. Số liệu này chưa bao gồm thời gian nạp mô hình Embedding trên CPU ở Runtime.

Ma trận Quyết định Lựa chọn Retriever

Table10.4

Retriever	Chất lượng (MRR/R@10)	Tốc độ / Chi phí	Thế mạnh chính	Hạn chế / Quyết định
TF-IDF	Thấp (0.6512 / 81.4%)	Rất nhanh / Nhẹ	Đơn giản, không phụ thuộc GPU	Không chọn
BM25	Khá (0.6856 / 85.1%)	Nhanh (56.8 QPS)	Từ khóa chính xác, khởi động tức thì	Mặc định Runtime UI
Dense	Tốt (0.7321 / 89.2%)	Tốn Memory CPU	Hiểu ngữ nghĩa, chống sai biệt từ	Tùy chọn nâng cao
Hybrid	Cao nhất (0.7682 / 91.6%)	Chậm hơn (44.8 QPS)	Toàn diện nhất về chất lượng	Mặc định Benchmark

Tại sao BM25 vẫn là Mặc định ở Runtime UI mặc dù Hybrid tốt nhất?

Đây là **Quyết định Vận hành (Operational Choice)**: Mô hình Dense làm tăng footprint bộ nhớ và thời gian nạp ban đầu trên CPU host. BM25 mang lại đường fallback cực kỳ ổn định, khởi động nhẹ nhàng và dễ chẩn đoán lỗi.

Các Chế độ Reader & Local LLM trong Runtime

Table 6.1

Runtime Key	Mô hình Thực thi	Chủng loại QA	Cơ chế Xử lý & Ngữ cảnh
xlmr	XLM-RoBERTa Large	Extractive QA	Trích xuất Exact Span từ các Passage ứng viên. Checkpoint chính thống của hệ thống.
phobert	PhoBERT / XLM-R Alias	Extractive QA	Khóa tương thích ngược (Compatibility Alias). Trong runtime hiện tại đang trở về XLM-R.
llm	LiquidAI LFM2.5-2.6B	Generative RAG	Mô hình sinh cục bộ 4-bit NF4. Sinh câu trả lời tự nhiên từ Top-5 Passages đã truy hồi.
llm_chat	LiquidAI LFM2.5-2.6B	Direct Chat	Trò chuyện đàm thoại trực tiếp dựa trên tri thức nội tại của LLM (Không gắn ngữ cảnh passage).

Tách biệt Kiến trúc

Hệ thống hỗ trợ song song hai triết lý: **Trích xuất chính xác (Extractive)** để đảm bảo khả năng truy vết nguồn gốc 100%, và **Tạo sinh (Generative RAG)** phục vụ các câu hỏi tổng hợp văn phong tự nhiên.

So sánh Mô hình: PhoBERT vs XLM-R vs LFM2.5

Table 6.2

Thông số / Metric	PhoBERT Base	XLM-RoBERTa Large	LiquidAI LFM2.5-2.6B
Tham số & Kích thước	134M (~0.50 GB)	559M (~2.08 GB)	2.6B (~2.5–3.0 GB VRAM)
Loại hình QA	Extractive Span	Extractive Span	Generative RAG / Chat
Smoke-10 Protocol	EM: 30.0 / F1: 30.0	EM: 60.0 / F1: 76.35	N/A (Chưa đo SQuAD metric)
Full Validation (3,814)	EM: 13.87 / F1: 36.25	Chưa có artifact full val	N/A (Output dạng văn bản tự do)
Answerable F1	32.96%	70.44% (Smoke-10)	N/A
Unanswerable Acc.	42.38%	100.0% (Smoke-10)	N/A
Truy vết Nguồn (Grounding)	Rất mạnh (Exact Span)	Mạnh nhất (Exact Offset)	Trung bình (Generative Text)

*Chú thích: Các metric chỉ so sánh trực tiếp khi cùng protocol và dataset. Smoke-10 dùng để kiểm tra nhanh giữa PhoBERT và XLM-R dưới cùng điều kiện thử nghiệm.

Tại sao chọn XLM-R làm Reader Chính?

Table 10.5

✓ Lý do XLM-R được chọn làm Reader Chính

- ✓ **Độ chính xác Span cao:** Đạt F1 76.35% trên bài kiểm tra Smoke protocol so với 30.0% của PhoBERT.
- ✓ **Khả năng gắn bằng chứng:** Bảo toàn 100% Exact Span và Offset vị trí từ trong Passage nguồn.
- ✓ **Tương thích Semantic Gates:** Cung cấp logit tường minh để tính margin từ chối câu hỏi unanswerable.

✗ Lý do LFM2.5 KHÔNG thay thế Reader Extractive

- ✗ **Không xuất Exact Span:** Văn bản do LLM sinh ra có thể diễn đạt lại, làm mất tính truy vết offset gốc.
- ✗ **Khó kiểm soát Semantic Gate:** LLM thế hệ mới dễ bị hallucination khi gặp câu hỏi unanswerable.
- ✗ **Độ trễ cao hơn:** Cần VRAM GPU dedicated và thời gian sinh token dài hơn.

Phân công Vai trò: XLM-R = Extractive Primary Reader chính cho bài toán QA tra cứu minh chứng chuẩn xác. LFM2.5 = Generative Extension mở rộng cho bài toán tổng hợp đa đoạn văn.

So sánh Luồng Extractive vs Generative QA

Architecture Comparison

✂ Nhánh Trích xuất (Extractive XLM-R)

Top-K Candidate Passages



XLM-R Span Predictor (Top 5 Spans)



Semantic Gate Cascade (Validate Boundary/Subject)



Exact Span Answer + Direct Source Offset

✂ Nhánh Sinh (Generative LFM2.5 RAG)

Top-5 Retrieved Passages



Prompt Construction + Context Grounding




LFM2.5 4-bit NF4 GPU Inference



Natural Synthesized Answer + Passage Reference

Chuỗi Semantic Gates & Kiểm soát Ngữ nghĩa

Để ngăn ngừa việc đưa ra câu trả lời vô nghĩa hoặc sai lệch ngữ nghĩa, mọi ứng viên (Candidate Span) bắt buộc phải trải qua **8 bước kiểm duyệt nghiêm ngặt**:



Ngưỡng Thắt chặt đặc biệt: Với các dạng câu hỏi nhạy cảm như BIRTH_TIME và DEATH_TIME, hệ thống nâng ngưỡng **Relation Score tối thiểu lên 0.90** để loại bỏ các mốc thời gian nhiễu khác trong văn bản.

Công thức Xếp hạng (Ranking Formula)

Scoring Weights

$$\text{Score}(c) = 0.30 \cdot \text{Sret} + 0.60 \cdot \text{Rc} + 0.10 \cdot \text{Stype} + 0.00 \cdot \text{Srelation}$$

30%

Sret (Retriever)

Điểm Min-Max Normalized từ tín hiệu truy hồi tài liệu.

60%

Rc (Reader Signal)

Điểm Reader sau khi phạt Fallback và nhân Boundary/Completeness.

10%

Stype (Answer Type)

Độ tương thích kiểu thực thể (Thực vật, Địa danh, Thời gian...)

0%*

Srelation (Mandatory Gate)

Trọng số 0.00 trong tổng đại số nhưng là Gate bắt buộc Pass/Fail.

Mô hình Thực nghiệm Ablation (A / AB / AC / ABC)

Ablation Concept

Cấu hình A (Reader Only)

Chỉ dùng Reader XLM-R trích xuất span thuần túy dựa trên Logit điểm số mà không qua tinh chỉnh hay kiểm tra ngữ nghĩa.

Cấu hình AB (Reader + Refinement)

Bổ sung bước Candidate Refinement (mở rộng/rút gọn ranh giới câu trả lời để đảm bảo tính trọn vẹn cú pháp).

Cấu hình AC (Reader + Semantic)

Lưu ý: Báo cáo ghi rõ biến thể AC chưa được đánh giá định lượng độc lập do chưa có Artifact tách riêng rẽ với Candidate Refinement.

Cấu hình ABC (Full Pipeline)

Tích hợp đầy đủ: Reader + Candidate Refinement + Semantic Validation Gates & Semantic Policy v2 hoàn chỉnh.

Kết quả Ablation & Phân tích Trade-off FP/FN

Table10.3

Đánh giá trên tập Semantic Holdout cố định (260 mẫu), thể hiện tác động của từng lớp xử lý:

Cấu hình Pipeline	Overall F1	Answerable F1	Unanswerable Acc. (%)	False Positive (%)	False Negative (%)
A (Reader Only)	24.63	25.02	22.50%	77.50%	15.00%
+ Refinement (AB)	22.05	21.97	22.50%	77.50%	17.27%
+ Subject Check	22.51	21.14	27.50%	72.50%	25.45%
+ Relation Check	20.59	17.97	35.00%	65.00%	31.82%
Full Pipeline (ABC)	26.56	20.94	57.50%	42.50%	44.09%

Quy luật Trade-off cốt lõi từ Báo cáo

Khi bật Semantic Gating đầy đủ (ABC): **False Positive giảm mạnh từ 77.50% xuống 42.50%** và Unanswerable Accuracy tăng từ 22.50% lên 57.50%. Hệ thống trở nên *thận trọng và an toàn hơn* khi từ chối các câu không nên trả lời, nhưng đổi lại làm **False Negative tăng từ 15.00% lên 44.09%** (bỏ lỡ một số câu có đáp án).

Bảng Quyết định Lựa chọn Cấu hình Pipeline

Table10.6

Biến thể	Lợi ích chính (Benefit)	Hạn chế / Chi phí (Cost)	Quyết định Lựa chọn
A (Reader Only)	Answerable F1 đạt 25.02, FN thấp nhất (15.00%)	False Positive quá cao (77.50%), rất dễ bị ảo giác	Chỉ dùng làm Baseline
AB (Refinement)	Cải thiện chuẩn hóa ranh giới cú pháp câu	Overall F1 giảm nhẹ so với A nếu không có Gate	Không chọn độc lập
AC (Semantic Only)	Lý thuyết giúp kiểm soát ngữ nghĩa	Chưa đủ bằng chứng thực nghiệm độc lập (Insufficient Evidence)	Chưa đánh giá riêng
ABC (Full Pipeline)	Overall F1 cao nhất (26.56), An toàn vượt trội (Unanswerable Acc 57.50%)	Tỷ lệ False Negative tăng (bị khắt khe hơn)	LỰA CHỌN CHÍNH THỨC

Kết luận: VIQA Nexus ưu tiên tiêu chí **Safety & Grounding** (Thà từ chối trả lời còn hơn trả lời sai bừa bãi), do đó ABC được chọn làm cấu hình tiêu chuẩn.

Gia sư Socratic Grounded (Socratic Tutor)

Socratic Engine

Quy trình 6 bước Sinh Câu hỏi Socratic

1. Lấy selected passage + top 12 retrieved passages.
2. Khôi phục Surface Form của Subject từ ngữ cảnh.
3. Phát hiện quan hệ (birth/death, location, event, cause, purpose...).
4. Khử trùng lặp câu hỏi trong lịch sử (Similarity threshold ≥ 0.72).
5. Kiểm tra tính có đáp án (Answerability threshold ≥ 0.62).
6. Xếp hạng lấy **Top ≤ 3 câu hỏi gọi mở 1-hop**.

Công thức Xếp hạng Socratic

$$S_{soc} = 0.5 A + 0.3 R + 0.2 N$$


- ✓ **A (Answerability):** Khả năng trả lời được từ corpus.
- ✓ **R (Relevance):** Độ liên quan tới chủ thể đang học.
- ✓ **N (Novelty):** Độ mới so với các câu đã hỏi.

🛡️ **Đảm bảo Không Hallucination:** Socratic Tutor dựa hoàn toàn trên Pattern Matching trong ngữ cảnh tài liệu, tuyệt đối không gọi API mô hình sinh ngoài.

Vòng lặp Phản hồi có Kiểm duyệt (Feedback Loop)

Human-in-the-Loop

Vòng đời Phản hồi (Feedback Lifecycle)



Nguyên tắc An toàn Dữ liệu

-  **KHÔNG TỰ HỌC RUNTIME:** Phản hồi chưa duyệt tuyệt đối KHÔNG làm thay đổi trọng số model hoặc corpus đang chạy.
-  **Chống Ô nhiễm Dữ liệu (Poisoning):** Chỉ dữ liệu được Chuyên gia duyệt (Approved) mới xuất ra train offline.
-  **Phân tích Điểm mù (Blind Spots):** Tự động phân loại rủi ro: CORPUS_GAP, RETRIEVAL_GAP, READER_SEMANTIC_GAP.

*Hiện tại file knowledge_blind_spot_report.json ghi nhận 0 bản ghi feedback thực tế (Dashboard đã sẵn sàng hạ tầng, chưa có dữ liệu từ người dùng thật).

Trạng thái Kiểm thử & Build Hệ thống (Test Status)

Table10.7

Lệnh thực thi	Trạng thái Build	Chi tiết Kết quả & Ghi chú
npm run build	THÀNH CÔNG	Build thành công 3,351 modules Vite/React (Cảnh báo 2 chunk JS Mari 3D > 500kB).
python -m pytest -q	178 PASSED / 10 FAILED	Tổng số 188 tests (Thời gian chạy 147.51 giây, 7 cảnh báo Deprecation).

🔧 Phân tích 10 Failure Tests (Không che giấu lỗi)

- **False Premise / Cause:** Sai thứ tự Rejection Reason trong Semantic.
 - **Question-Type Regressions:** Lỗi phân loại Alias, Location & Quantity.
- **Fallback Span:** Độ dài span fallback lớn hơn kỳ vọng.
 - **Config Stale Weights:** 2 test cũ vẫn kỳ vọng Reader Weight 0.50 (Config mới là 0.60).

Các Giới hạn Quan trọng của Hệ thống

Nhóm Giới hạn	Mô tả Chi tiết Giới hạn	Tác động đến Hệ thống
Chất lượng Reader	Answerable EM chỉ đạt 0.79% trên full validation; Checkpoint vẫn ở mức Experimental.	Span trích xuất dễ bị lệch dài/ngắn hơn tiêu chuẩn.
Semantic Trade-off	Thắt chặt Gate giúp giảm False Positive nhưng làm False Negative tăng lên 44.09%.	Hệ thống đôi khi quá cẩn trọng, từ chối cả câu có đáp án.
Lệch tầng Benchmark	Offline benchmark đo ở cấp Document-level; Online API phục vụ ở cấp Passage-level.	Kết quả benchmark offline không đại diện 1:1 cho SLA runtime.
Bảo mật API Review	Các API Review feedback & Document Submission chưa tích hợp Auth / RBAC.	Mới dừng ở mức Prototype nghiên cứu cục bộ an toàn.

Lộ trình Phát triển Ưu tiên (Roadmap)

Table 11.1

Khẩn cấp **Mức P0**

-  Đồng bộ Evaluation Manifest & Tái lập Benchmark.
-  Sửa triệt để 10 lỗi Semantic Test Regressions.
-  Thống nhất Dashboard Evaluation với Active Checkpoint.

Trung hạn **Mức P1**

-  Huấn luyện lại Reader với Boundary-Aware Loss.
-  Xây dựng Benchmark End-to-End độc lập.
-  Bổ sung Authentication & RBAC cho Feedback APIs.

Mức P2

-  Tối ưu hóa Latency CPU & Code Splitting Mari 3D.
-  Thực hiện Human User Study cho Gia sư Socratic.
-  Mở rộng khả năng tự động Promote Checkpoint.

Kết luận & Thông điệp Cốt lõi

Conclusion

4 Đóng góp Chính của VIQA Nexus

- ✓ **Hệ thống QA Có Dẫn Nguồn:** Đảm bảo 100% tính minh chứng, từ chối an toàn khi thiếu bằng chứng.
- ✓ **Hybrid Retriever Vượt Trội:** Đạt MRR 0.7682 và Recall@10 91.56% trên 7,301 câu hỏi test.
- ✓ **Extractive & Generative Song Hành:** XLM-R đóng vai trò Reader trích xuất chính xác; LFM2.5 mở rộng diễn đạt RAG.
- ✓ **Minh bạch & Có thể Kiểm toán:** Socratic Tutor grounded và Vòng lặp phản hồi Human-in-the-Loop an toàn.

Trạng thái Công bố

VIQA Nexus vẫn chỉ là một Demo lý thuyết để cần thời gian trở thành một **Research Prototype hoàn chỉnh** và chưa thể chần đoán mọi quyết định

- ⚠ **Hệ thống hiện chưa tuyên bố Production-Ready;** cần tiếp tục hoàn thiện Test Suite và nâng cao Answerable EM của Reader trước khi triển khai thực tế.

VIQA NEXUS PRESENTATION

Cảm ơn Thầy và các Bạn!

Hỏi & Đáp — Q&A Session

Mã nguồn dự án: https://github.com/duong158/QA_system